

Informe construcción del modelo de series de tiempo

Preparación de los datos

Normalización de la variable objetivo

Se aplica una normalización tipo *z-score* sobre la variable objetivo, con el fin de estabilizar el entrenamiento del modelo.

- Se centra la variable en la media
- Se escala por la desviación estándar

Esta transformación permite que el modelo trabaje en una escala controlada, mejorando la convergencia y evitando que valores extremos dominen el proceso de aprendizaje.

Construcción del dataset

Estructura de entrada

Cada muestra entregada al modelo está compuesta por una secuencia de 24 observaciones, cada una con 28 variables, mientras que la salida corresponde a un único valor escalar futuro de la variable objetivo. Esta formulación convierte el problema en un esquema de tipo *many-to-one*, en el cual una secuencia temporal completa es resumida en una única predicción que busca el valor de las bicicletas en la siguiente hora teniendo en cuenta el comportamiento de las últimas 24

Arquitectura del modelo

Modelo propuesto

Se implementa un modelo SimpleLSTMModel compuesto por:

- Una capa LSTM
- Tamaño de estado oculto: 128 unidades

- Configuración bidireccional activada
- Capa final totalmente conectada de 256 neuronas ($128 \times 2 = 256$) ya que al ser bidireccional concatena un vector de salida con el otro

Uso de una sola capa LSTM

El uso de una sola capa LSTM responde a la naturaleza del problema, donde la longitud de la secuencia es 24 pasos, lo que reduce la necesidad de modelar jerarquías temporales profundas.

Configuración de entrenamiento

El modelo se entrenó usando el optimizador Adam con una tasa de aprendizaje de 0.001, buscando un buen balance entre aprender rápido y mantener estabilidad durante el entrenamiento. Como el problema es de regresión, el objetivo es predecir valores continuos, por lo que se utiliza el MAE (error absoluto medio) como métrica principal. En este caso no se usa una función como *softmax* en la salida, ya que no se están clasificando datos sino estimando un valor numérico.

Además, se implementó *early stopping* con una paciencia de 10 épocas para evitar que el modelo se sobreentrene. El mejor resultado se obtuvo en la época 11 con un MAE de 36.65. A partir de ahí no hubo mejoras, por lo que el entrenamiento se detuvo en la época 18. Esto indica que el modelo aprende rápido al inicio, pero luego deja de mejorar y empieza a perder capacidad de generalizar.

Conclusión

La ejecución del modelo evidencia que la arquitectura propuesta logra capturar patrones relevantes de corto plazo en la serie de tiempo, alcanzando su mejor desempeño en una etapa temprana del entrenamiento (época 11).

El comportamiento posterior, donde no se presentan mejoras y se activa el *early stopping*, sugiere la presencia de sobreajuste leve, lo cual es consistente con:

- Una ventana temporal corta (24 pasos)
- Un modelo con capacidad suficiente (LSTM bidireccional)

